



國立台灣科技大學
機械工程系

強化學習專題報告

姓名： B11103132 宋奕達

中華民國 115 年 04 月 26 日

強化學習作業報告

一、實驗目的

本次作業使用 GridWorld 環境比較四種強化學習方法：

方法：Q-learning、SARSA、DQN、Deep SARSA

二、環境與實驗設定

GridWorld 大小為 11x11。Agent 的動作空間為四個方向：上、下、左、右，圖中以箭頭 $\uparrow$ $\downarrow$ $\leftarrow$ $\rightarrow$ 表示。每回合從隨機合法且非終止的白色格子開始。Reward 設定如下：

格子類型	Reward	終止狀態
白格	-1	否
黑格	-100	是
綠色目標格	+100	是

三、Q-learning 與 SARSA 比較

方法差異

Q-learning 是 off-policy 方法，更新時使用下一狀態中最大的 Q 值：

$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$$

因此 Q-learning 學的是「假設下一步都採 greedy action」的最佳策略，即使訓練過程仍有 epsilon-greedy 探索。

SARSA 是 on-policy 方法，更新時使用實際依目前策略選出的下一個動作：

$$Q(s,a) \leftarrow Q(s,a) + \alpha [r + \gamma Q(s',a') - Q(s,a)]$$

所以 SARSA 會把探索行為本身的風險也納入估計，policy 通常會比 Q-learning 保守，尤其在靠近懲罰格或牆壁時更明顯。

實驗觀察

從 $\epsilon_{start} = 0.5$ 的曲線可看出，Q-learning 在約第 230 到 260 回合後 success rate 快速上升，之後幾乎維持在 1.0，episode return 也提升到接近正值高報酬區間，episode length 最後下降到較短步數。這代表 Q-learning 成功找到穩定通往目標的策略。

(圖片最後成功率下降不是因為模型有問題，而是因為平均線會因為幾次失敗而下降，可能因為最後選的起點離終點遠，導致失敗。)

SARSA 也能學到可達目標的策略，但相較 Q-learning，後期曲線比較震盪。success rate 在上升後仍會出現下降，episode length 也有較大的尖峰，代表 SARSA 在訓練後期仍較容易受到實際探索動作影響。這符合 on-policy 的特性：SARSA 評估的是「包含探索行為」的策略，而不是純 greedy 最佳策略。



三組 `epsilon_start` 在後期的 `success rate` 與 `policy` 差異不大，表示在此 `GridWorld` 中，`Q-learning` 對 `epsilon_start` 的敏感度不高；`epsilon_start` 主要影響早期探索與收斂速度，而非最終策略品質。可以看到 0.8 的一開始成功率超低，主要就是因為一開始模型還未完善，一直照著策略走所以走不到終點。

小結



比較項目	Q-learning	SARSA
Policy 類型	Off-policy	On-policy
更新目標	下一狀態最大 Q 值	實際選到的下一動作 Q 值
收斂表現	成功率較快穩定到 1.0	可學成功，但震盪較明顯
Episode length	後期較短且穩定	後期仍有長 episode 尖峰
Policy 風格	較偏向最短或高報酬路徑	較受探索風險影響

圖片展示



Q Learning



Episode=0.2





Episode=0.5





Episode=0.8



sarsa



Episode=0.2



Episode=0.5



Episode=0.8

四、DQN 與 Deep SARSA 比較

方法差異

DQN 是 Q-learning 的深度版本，用神經網路近似 Q table。程式中 DQN 使用 experience replay 與 target network，使更新目標較穩定：

```
target = r + gamma max_a' Q_target(s',a')
```

Deep SARSA 則是 SARSA 的深度版本，也用神經網路近似 Q 值，但 target 使用實際依 epsilon-greedy 選到的下一個動作：

```
target = r + gamma Q(s',a')
```

本次 Deep SARSA 沒有 replay buffer，也沒有 target network。

實驗觀察

因為原本助教給的範例成功率很低，因此我調整了一些部份，狀態由原本的 `(row, col)` 正規化座標改成 one-hot encoding，並將訓練回合增加到 2000 episodes，同時使用 Huber loss 後 success rate 有明顯改善。以 `epsilon\_start = 0.5` 為例，後期 success rate moving average 可上升到約 0.7 到 0.9，episode return 也從長期負值逐漸提升到正值區間，表示 DQN 已經能學到較穩定的到達目標策略。

Deep SARSA 雖然也套用 one-hot encoding、2000 episodes、Huber loss 與 gradient clipping，但 success rate 仍然偏低，moving average 大多接近 0。這表示 Deep SARSA 在此迷宮中仍不穩定，主要原因是它是 on-policy 方法，而且目前實作沒有 replay buffer 與 target network；每一步更新都會直接受到當下 epsilon-greedy 探索路徑影響，因此比 DQN 更容易被失敗路徑或撞牆懲罰干擾。

小結

比較項目	DQN	Deep SARSA
Policy 類型	Off-policy	On-policy
更新目標	max over next actions	實際選到的 next action
穩定機制	Replay buffer、target network	無
本次結果	改成 one-hot 後成功率明顯上升	改成 one-hot 後仍偏低
解讀	replay buffer 與 target network 有助於穩定學習	on-policy 且無 replay buffer，仍容易震盪

五、epsilon_start 對結果的影響

1. `epsilon\_start = 0.2`

較低的 epsilon 代表一開始探索較少，agent 比較早依賴目前 Q 值或 network 輸出。對 tabular 方法來說，如果初期剛好探索到有效路徑，可能較快穩定；但也可能因為探索不足而卡在局部策略。對 DQN 來說，`epsilon\_start = 0.2` 有一定改善，但後期穩定性不如 `0.5` 明顯。對 Deep SARSA 來說，低 epsilon 仍無法明顯提高成功率。

2. `epsilon\_start = 0.5`

中等 epsilon 在 tabular Q-learning 與 SARSA 中效果較清楚。Q-learning 在中後期成功率上升到接近 1.0，return 提升，episode length 降低。SARSA 也能成功學到，但曲線震盪較大。這組參數在 tabular 方法中可視為探索與利用較平衡的設定。

3. `epsilon\_start = 0.8`

較高 epsilon 代表前期探索更多。優點是比較容易走到更多狀態與嘗試不同路徑；缺點是訓練前期會有更多隨機行為，容易撞到黑格或走較長路徑，因此 return 較差、episode length 較不穩。

DQN 在 `epsilon\_start = 0.8` 時仍能逐漸改善，但波動比 `0.5` 更明顯。Deep SARSA 則仍未形成穩定成功率，顯示單純增加探索不足以解決其更新不穩定問題。

整體比較

epsilon_start	探索程度	對 learning curve 的影響	對 success rate 的影響	對 episode length 的影響	對 policy 的影響
0.2	低	較快進入利用，但可能探索不足	Tabular 可成功；DQN 有改善；Deep SARSA 仍低	若學成會較短，若沒學成則仍不穩	容易受初期經驗影響
0.5	中	探索與利用較平衡	Q-learning 最穩；DQN 改善最明顯；SARSA 可成功但較震盪	Q-learning 與 DQN 後期較短，SARSA 尖峰較多	較容易形成可到達目標的 policy
0.8	高	前期 return 較差、波動較大	DQN 可逐漸改善但震盪較大；Deep SARSA 仍不穩	前期較長，可能有較多尖峰	探索較廣，但後期是否收斂取決於更新穩定性



六、Policy 圖觀察

Policy block 圖顯示訓練後每個非終止格的 greedy action。Tabular 方法的 policy 圖較能看出箭頭逐漸指向通往 goal 的方向，尤其 Q-learning 的結果與 success rate 接近 1.0 的曲線互相呼應。



DQN 與 Deep SARSA 的 policy 圖雖然都能輸出箭頭，但需要搭配 success rate 一起解讀。DQN 在改成 one-hot 後，policy 圖與後期成功率上升較能互相對應；Deep SARSA 的 policy 圖則仍不代表已形成可靠策略，因為其 success rate moving average 仍偏低。

圖片展示



DQN



Episode=0.2





Episode=0.5





Episode=0.8


Deep Sarsa



Episode=0.2



Episode=0.5



七、結論

本次 GridWorld 實驗中，tabular 方法明顯優於 deep 方法。Q-learning 成功率最高且後期最穩定，顯示在離散且狀態數不大的 GridWorld 中，Q table 能有效記錄每個 state-action 的價值。SARSA 也能學到策略，但因為是 on-policy，會把 epsilon-greedy 探索造成的風險納入更新，因此 return、success rate 與 episode length 都比 Q-learning 更震盪。

DQN 在改成 one-hot state representation、增加訓練回合並使用 Huber loss 後，成功率明顯改善，代表 state representation 對神經網路方法非常重要。原本只用 (row, col) 座標輸入時，網路很難表示迷宮中不連續的牆壁與轉彎結構；one-hot 則更接近 tabular 方法，能讓每個格子有較獨立的表示。

Deep SARSA 即使使用相同的 one-hot 與穩定化技巧，成功率仍然偏低。這表示在此環境中，Deep SARSA 的 on-policy 更新較容易受到探索動作與負 reward 干擾；相較之下，DQN 的 replay buffer 與 target network 對穩定訓練有明顯幫助。

針對 epsilon_start 的比較，`0.2` 探索較少，`0.8` 探索較多但前期波動較大而且成功率較低，`0.5` 在 tabular 方法中呈現較好的探索與利用平衡。整體而言，本次最穩定的組合是 Q-learning 搭配中等 epsilon 起始值。

最後有一些我在做的過程中感到疑惑並找到解答的內容，第一點是關於“targetnet”，我一開始對於 targetnet 這部分其實感到非常的難以理解，我的一開始的想法是在 DQN 裡有使用到一個 [max_next_q] 這裡是使用 targetnet，是從 qnet 複製出來的，一開始也不准，這樣要如何去訓練？，Ai 是這樣說：target_net 一開始不准，但穩定，reward 一直是真實訊號，經過很多 episode，真實 reward 會透過 Bellman update 慢慢傳回前面的 state，target_net 只是讓這個傳播過程不要太晃。所以最後會因為 reward 的影響，讓數值逼近現實值。